# Hash Table 流程圖、學習歷程與 Hash Table 與 Hash Function 原理

## 一、 Hash Table 流程圖

### 1. 建立 Hash Table 並決定其長度

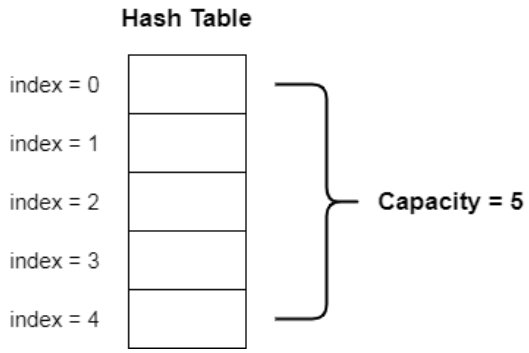


### 2. 新增資料進入 Hash Table

- 新增非數值型態資料「dog」進入 Hash Table 中。
- 計算該資料須存放的位置: 以 MD5 編碼並將編碼結果轉成十進位，並將該數值除以 Hash Table 的長度求餘數。
  「dog」以 MD5 編碼並將編碼結果轉成十進位後為 909720205502626453 5080901219663267845，除以 Hash Table 的長度求餘數為 0。
- 將「dog」存放至 Hash Table 的 index=0 的位置。

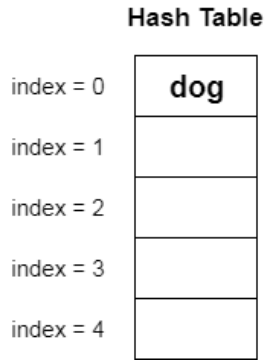


- 新增非數值型態資料「pig」進入 Hash Table 中。
- 「pig」 以 MD5 編碼並將編碼結果轉成十進位後為 909720205502626 4535080901219663267845，除以 Hash Table 的長度求餘數為 2。
- 將「pig」存放至 Hash Table 的 index=2 的位置。

- 新增非數值型態資料「cat」進入 Hash Table 中。
- 「cat」 以 MD5 編碼並將編碼結果轉成十進位後為 277102220249073555409885156483852860632，除以 Hash Table 的長度求餘數為 2。
- 將「cat」存放至 Hash Table 的 index=2 的位置。
- 在 index=2 的位置發生 Collision，利用 Chaining 的方法，使用 Linked list 將分在 Hash Table 中同一個 index 的資料串起來，將「cat」接在「pig」後面。

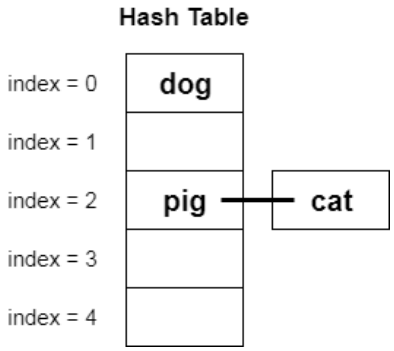


**3. 刪除 Hash Table 中資料**

- 在 Hash Table 中刪除新增非數值型態資料「cat」。
- 計算該資料須存放的位置: 以 MD5 編碼並將編碼結果轉成十進位，並將該數值除以 Hash Table 的長度求餘數。
  「cat」 以 MD5 編碼並將編碼結果轉成十進位後為 277102220249073555409885156483852860632，除以 Hash Table 的長度求餘數為 2。
- 訪尋位於 Hash Table 中 index=2 位置的 Linkedlist，並刪除含有「cat」的 node。

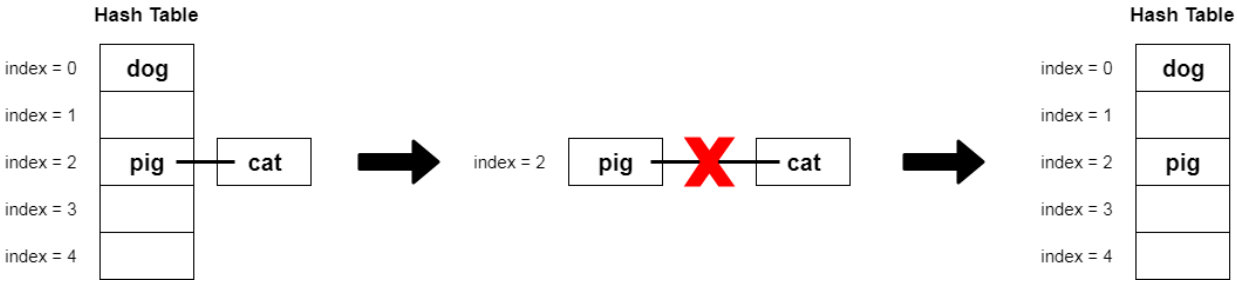


**4. 查找 Hash Table 中的資料**

- 在 Hash Table 中查找非數值型態資料「cat」。
- 計算該資料須存放的位置: 以 MD5 編碼並將編碼結果轉成十進位，並將該數值除以 Hash Table 的長度求餘數。
  「cat」 以 MD5 編碼並將編碼結果轉成十進位後為 277102220249073555409885156483852860632，除以 Hash Table 的長度求餘數為 2。
- 訪尋位於 Hash Table 中 index=2 位置的 Linkedlist，並查找含有「cat」的 node。如找到符合條件的 node 則返回 "cat" is in the hash table.。

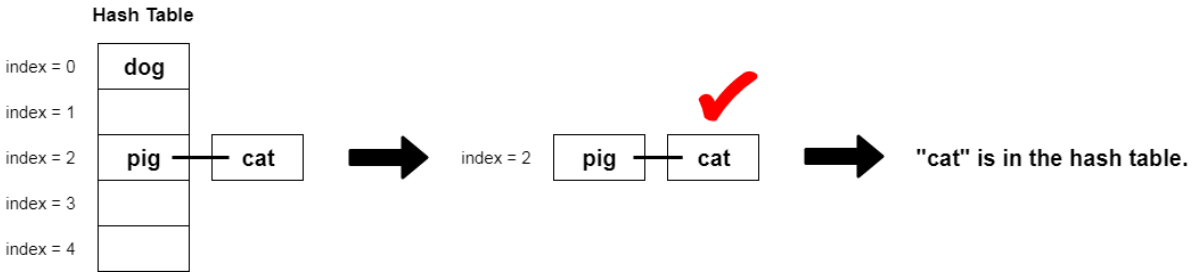


## 二、 Hash Table 學習歷程

### 1. 嘗試加入 MyLinkedList 的寫法

加入 MyLinkedList 的 class，該 class 的原理是能在一條 Linked List 中做新增、刪除、查詢的功能，因此在 MyHashSet 的 class 中只需先在 Hash Table 的每個 Index 放入空的 Linked List，然後在做新增、刪除、查詢時，只需先找到輸入的 key 值在 Hash Table 的位置後，再呼叫位於該位置的 MyLinkedList，並利用該 class 的功能做新增、刪除、查詢。程式碼變得更清楚簡潔。

```
1 class ListNode:
2     def __init__(self, val):
3         self.val = val
4         self.next = None
5
6 class MyLinkedList:
7     def __init__(self):
8         self.head = None
9         self.size=0
10
11    def order(self):
12        curnode = self.head
13        while curnode!=None:
14            print(curnode.val,end=' ')
15            curnode = curnode.next
16        print('\n')
17
18    def addAtTail(self,val):
19        if self.head == None:
20            self.head = ListNode(val)
21            self.size+=1
22            return
23        curnode = self.head
24        while curnode.next != None:
25            curnode = curnode.next
26        curnode.next = ListNode(val)
27        self.size+=1
28
29    def deleteValue(self,val):
30        while self.searchValue(val)==True:
31            if self.head.val==val:
32                tmp=self.head.next
33                self.head=tmp
34                self.size-=1
35            else:
36                pre=self.head
37                curnode=self.head
38                while curnode!=None:
39                    if curnode.val==val:
40                        pre.next=curnode.next
41                        self.size-=1
42                        break
43                    pre=curnode
44                    curnode=curnode.next
45
46    def searchValue(self,val):
47        curnode=self.head
48        while curnode!=None:
49            if curnode.val==val:
50                return True
51            curnode=curnode.next
52        return False
```

第 57 行的 self.data 不能寫:

self.[ MyLinkedList()]*capacity

這樣會讓位於每個 Hash Table 位置的 MyLinkedList 都一樣，這樣會導致在某個 Hash Table 位置做新增、刪除、查找時，對每個位置的 MyLinkedLis 都做上述的動作，而不只是在輸入的 key 值在 Hash Table 的位置做而已。

要寫:

for i in range(capacity):

    self.data[i]=MyLinkedList()

或是

self.data=[MyLinkedList() for x in range(0, capacity)]

一個一個位置去索引並賦值 MyLinkedList()。

```
54 class MyHashSet:
55     def __init__(self, capacity=5):
56         self.capacity = capacity
57         self.data = [MyLinkedList() for x in range(0, capacity)]
58
59     def add(self, key):
60         index = self.hash(key)
61         linkedlist = self.data[index]
62         linkedlist.addAtTail(key)
63
64     def remove(self, key):
65         index = self.hash(key)
66         linkedlist = self.data[index]
67         linkedlist.deleteValue(key)
68
69     def contains(self, key):
70         index = self.hash(key)
71         linkedlist = self.data[index]
```

另外在第 29 行 deleteValue 不能寫:

```
1 def deleteValue(self,val):
2     pre=self.head
3     curnode=self.head.next
4     while curnode!=None:
5         if curnode.val==val:
6             pre.next=curnode.next
7         pre=curnode
8         curnode=curnode.next
9     if self.head.val==val:
10        tmp=self.head.next
11        self.head=tmp
```

上述的方法是打算一次將所有欲刪除的值刪除，但會發生以下問題，導致無法刪完所有的值:

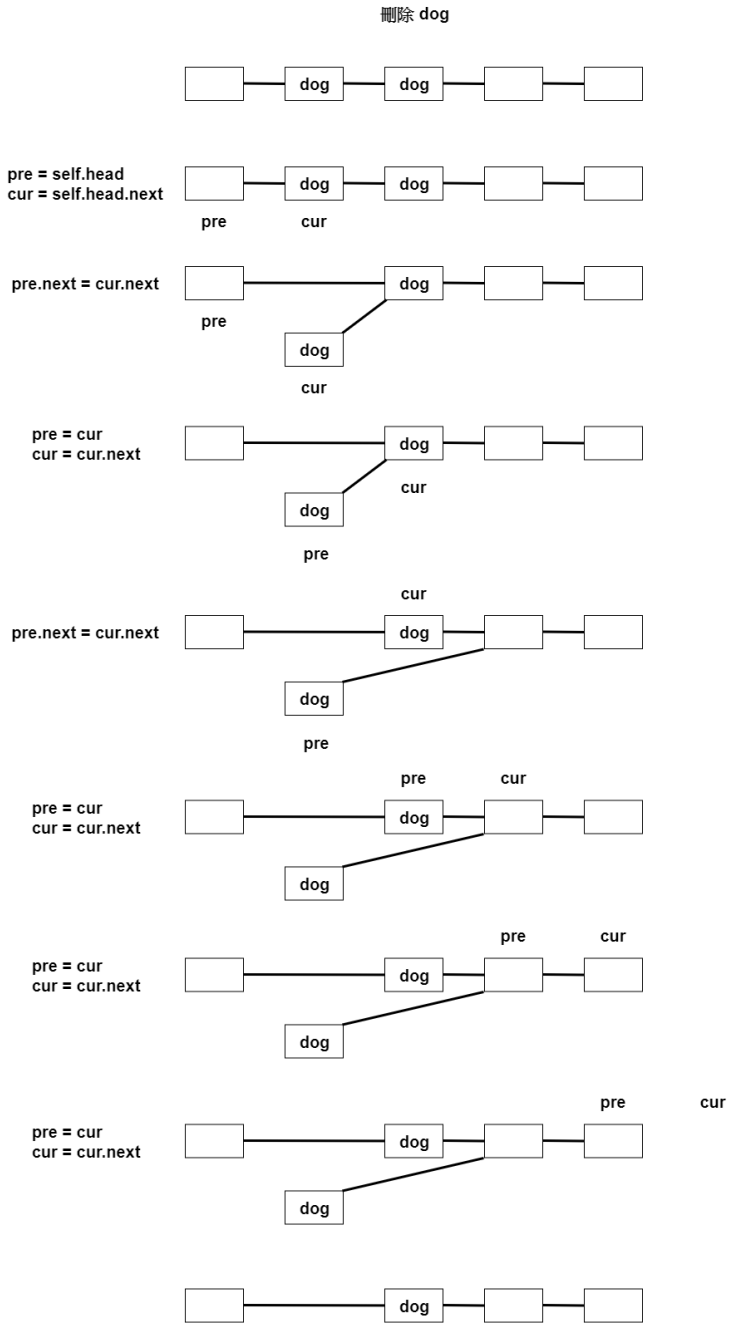

## 2. Remove 寫法注意

在第 57 行的 return 一定要加，或是改成 break，不然會有無窮迴圈的情況。原因在於在第 56 行讓 self.data[index]=None 時並不會讓 node 變成 None，只會讓 self.searchValue 重複返回 True，然後進入 node.next==None 的條件中，然後不斷循環。

```
25 class ListNode:
26     def __init__(self, val):
27         self.val = val
28         self.next = None
29 
30 class MyHashSet:
31     def __init__(self, capacity=5):
32         self.capacity = capacity
33         self.data = [None] * capacity
34 
35     def add(self, key):
36         index = self.hash(key)
37         if self.data[index]==None:
38             self.data[index]=ListNode(None)
39         node = self.data[index]
40         if node.val==None:
41             node.val=key
42         else:
43             curnode = node
44             while curnode.next != None:
45                 curnode = curnode.next
46             curnode.next = ListNode(key)
47 
48     def remove(self, key):
49         index = self.hash(key)
50         if self.data[index]==None:
51             return
52         node = self.data[index]
53         while self.searchValue(key,node)==True:
54             if node.val==key:
55                 if node.next==None:
56                     self.data[index]=None
57                     return #注意! 一定要加，不然會無窮迴圈，因為no
58                 else:
59                     node.val=node.next.val
60                     node.next=node.next.next
61             else:
62                 pre=node
63                 curnode=node
64                 while curnode!=None:
65                     if curnode.val==key:
66                         pre.next=curnode.next
67                         break
68                     pre=curnode
69                     curnode=curnode.next
70 
71     def contains(self, key):
72         index = self.hash(key)
73         if self.data[index]==None:
74             return False
75         node = self.data[index]
76         outcome=self.searchValue(key,node)
77         return outcome
78 
79     def hash(self,key):
80         from Cryptodome.Hash import MD5
81         h = int(MD5.new(key.encode('utf-8')).hexdigest(),16)
82         index = h % self.capacity
83         return index
84     def orderAll(self):
85         for i,j in zip(self.data,range(0, self.capacity)):
86             print(j,end=' ')
87             self.order(i)
88 
89     def searchValue(self,key,node):
90         curnode=node
91         while curnode!=None:
92             if curnode.val==key:
93                 return True
94             curnode=curnode.next
95         return False
96 
97     def order(self,node):
98         curnode = node
99         while curnode!=None:
100            print(curnode.val,end=' ')
101            curnode = curnode.next
102        print('\n')
103
```

## 3. 程式碼說明

**def __init__(self, capacity=5):**

- 決定 Hash Table 長度。
- 建立 Hash Table，Hash Table 中每個位置的初始值為 None。

**def add(self, key):**

- 透過 hash 函式找出 key 值在 Hash Table 的位置。
- 如果該位置的值尚為 None，則賦值為一個空的 node。
- 接下來的動作與 LinkedList 中 addAtTail 函式相似

**def remove(self, key):**

- 透過 hash 函式找出 key 值在 Hash Table 的位置。
- 採用一次只刪除一個值，並透過 while 迴圈，每刪完一次就從頭到尾訪尋一次 Linked List，刪到 Linked List 中沒有該值為止。
- 分兩種情況討論: 1. 欲刪除的值位於 Linked List 的首位 2. 欲刪除的值位於 Linked List 其他位置。刪除方法與 LinkedList 中 deleteAtIndex 函式相似，只是這次刪除的條件是 curnode.val==key。

**def contains(self, key):**

- 透過 hash 函式找出 key 值在 Hash Table 的位置。
- 利用 searchValue 函式查找 LinkedList 中是否有欲查找的 key。查找方式與 LinkedList 中 get 函式相似，只是這次查找的條件是 curnode.val==key。

```
25 class ListNode:
26     def __init__(self, val):
27         self.val = val
28         self.next = None
29 
30 class MyHashSet:
31     def __init__(self, capacity=5):
32         self.capacity = capacity
33         self.data = [None] * capacity
34 
35     def add(self, key):
36         index = self.hash(key)
37         if self.data[index]==None:
38             self.data[index]=ListNode(None)
39         node = self.data[index]
40         if node.val==None:
41             node.val=key
42         else:
43             curnode = node
44             while curnode.next != None:
45                 curnode = curnode.next
46             curnode.next = ListNode(key)
47 
48     def remove(self, key):
49         index = self.hash(key)
50         if self.data[index]==None:
51             return
52         node = self.data[index]
53         while self.searchValue(key,node)==True:
54             if node.val==key:
55                 if node.next==None:
56                     self.data[index]=None
57                     return #注意! 一定要加，不然會無窮迴圈，因為no
58                 else:
59                     node.val=node.next.val
60                     node.next=node.next.next
61             else:
62                 pre=node
63                 curnode=node
64                 while curnode!=None:
65                     if curnode.val==key:
66                         pre.next=curnode.next
67                         break
68                     pre=curnode
69                     curnode=curnode.next
70 
71     def contains(self, key):
72         index = self.hash(key)
73         if self.data[index]==None:
74             return False
75         node = self.data[index]
76         outcome=self.searchValue(key,node)
77         return outcome
78 
79     def hash(self,key):
80         from Cryptodome.Hash import MD5
81         h = int(MD5.new(key.encode('utf-8')).hexdigest(),16)
82         index = h % self.capacity
83         return index
84     def orderAll(self):
85         for i,j in zip(self.data,range(0, self.capacity)):
86             print(j,end=' ')
87             self.order(i)
88 
89     def searchValue(self,key,node):
90         curnode=node
91         while curnode!=None:
92             if curnode.val==key:
93                 return True
94             curnode=curnode.next
95         return False
96 
97     def order(self,node):
98         curnode = node
99         while curnode!=None:
100             print(curnode.val,end=' ')
101             curnode = curnode.next
102         print('\n')
103 
```

## 三、 Hash Table 與 Hash Function 原理

### I. Hash Table 與 Hash Function 概念

根據鍵（Key）而直接查詢在內存存儲位置的資料結構。通過一個關於計算鍵值的函數，將所需查詢的數據映射到表中一個位置來查詢記錄，該方法也加快了查找速度。此映射函數稱做雜湊函數 (Hash Function)，存放記錄的數組稱做雜湊表 (Hash Table)。

以查找與儲存姓名為例。在未使用 Hash Table 與 Hash Function 的情況下，如欲儲存一百位人名就直接將一個個人名儲存起來，假設當要查找「Albert」該人名時，就只能將「Albert」這三個字一個個與一百個人名比對，共做一百次比對，該方法相當耗時。當使用 Hash Table 與 Hash Function 的方法後，在儲存資料時，可以先透過 Hash Function 將欲儲存的人名轉換成人名字首，如將「Albert」轉換成「A」儲存、將「Alice」轉換成「A」儲存、將「Charles」轉換成「C」儲存……。經過轉換後，最終儲存的種類只會有 26 種可能 (英文有 26 個字母)，該 26 種儲存的種類構成了一個數組，該數組即為 Hash Table，長度為 26，同樣被轉成「A」的人名被視為一類，並儲存在「A」類別中……。如欲查找「Albert」該人名時，先透過 Hash Function 將「Albert」轉換成「A」。此時只需查找同樣是「A」的儲存種類即可，其他種類則不必查找，並在該種類下找到「Albert」這個人名。該方法省下了許多不必要的比對。以上是 Hash Table 與 Hash Function 來儲存和查找資料的例子。

### II. Hash Table 介紹

因此在 Hash Table 這個數組中，每個位置代表資料經 Hash Function 轉換後的數值，原本的資料稱為鍵值(Key)，經 Hash Function 轉換後的數值則為 Hash Table 的索引值(Index)。若用到的 Key 的數量為 n，Table 的大小為 m，Hash Function 為 h，那麼 m 等於 h(n)的種類；index=h(Key)，h(Key)即為 Hash Table 的 index。然而很可能發生 Collision 的情況，很可能有多個 Key 值經 Hash Function 轉換後被分在 Hash Table 中同一個 index，此時就可以利用 Chaining 的方法，使用 Linked list 把被分在 Hash Table 中同一個 index 的 Key 值串起來。有了 Linked list 處理被分配到同一個 index 的 key 值，在 Hash Table 中每個 index 的 Linked list 有幾種資料處理: 1. Add: 先利用 Hash Function 取得 Table 的 index，接著再利用 addAtTail 每個資料依序串起來。2. Contains: 先利用 Hash Function 取得 Table 的 index，接著再利用 Search 找到欲查找的資料。3. Remove: 先利用 Hash Function 取得 Table 的 index，接著再利用 Delete 刪除欲刪除的資料。

## III. Hash Function 介紹

優秀的 Hash Function (h)應具備以下特徵：

1. 定義 h()的定義域(domain)為整個 Key 的宇集合 U，值域(range)應小於 Table 的大小 m：h:U→{0,1,...,m−1}, where|U|≫m
2. 盡可能讓 Key 在經過 Hash Function 後，值域(也就是 Table 的 index)能夠平均分佈，如此才不會讓兩筆資料存進同一個 Table 的 index，而發生 Collision 的情況。

若把 Table 想像成「書桌」，index 想像成書桌的「抽屜」，那麼為了要能更快速找到物品，當然是希望「每一個抽屜只放一個物品」，如此一來，只要拿著 Key，透過 Hash Function 找到對應的抽屜，就能保證是該 Key 所要找的物品。反之，如果同一個抽屜裡有兩個以上的物品時，便有可能找錯物品。

Hash Function (h) 其中一種方法為 Division Method，假設 Table 大小為 m，經 Hash Function 轉換後的鍵值(key)為鍵值除以 Table 大小的餘數，該餘數即為該鍵值在 Hash Table 中的 Index:

$$h(Key) = Key \bmod m$$

例如選定 Table 大小為 m=8，的 Key 與 Table 之 index 將有對應關係如下：

h(14) = 14 mod 8 = 6

代表「鍵值 14」要儲存在 Hash Table「index=6」的位置。

h(23) = 23 mod 8 = 7

代表「編號 23」要儲存在 Hash Table「index=7」的位置。

h(46) = 46 mod 8 = 6

代表「編號 46」要儲存在 Hash Table「index=6」的位置。

h(50) = 50 mod 8 = 2

代表「編號 50」要儲存在 Hash Table「index=2」的位置。

如欲儲存和查找的資料非數值型態，可以透過編碼將該型態資料轉換成數值型態資料，如 MD5 編碼。

## 四、 參考資料

### 1. Hash Table 與 Hash Function 原理

- https://zh.wikipedia.org/wiki/%E5%93%88%E5%B8%8C%E8%A1%A8
- http://alrightchiu.github.io/SecondRound/hash-tableintrojian-jie.html#ht
- http://alrightchiu.github.io/SecondRound/hash-tablechaining.html

### 2. 程式碼

- 參考自己原創的 LinkedList 程式碼:
  Github/DSA/Linked List 資料夾/ linked list_原創.py
  https://github.com/albert0796/DSA.git